

Track-to-Track Füzyon: Literatür Araştırması ve Sistem Tasarımı Raporu

Çoklu Sensör Ortamında Association ve Füzyon

29 Haziran 2026

Ebrar Pınar Kuz

Giriş

Bu rapor, multi-sensor track-to-track füzyon konusunda yapılan literatür araştırmasını ve önerilen sistem mimarisini özetlemektedir. Hedef senaryo: birden fazla sensörün asenkron çalıştığı, no feedback ve her sensörden hedef bazında konum, hız, track ID ve track quality bilgilerinin alınabildiği bir algılama sistemidir.

BÖLÜM 1: Temel Kavramlar

1.1 Track-to-Track Füzyon Nedir?

Birden fazla sensör aynı hedefi takip ettiğinde, her sensör kendi içinde bir track üretir. Bu trackler füzyon merkezinde birleştirilerek daha doğru ve güvenilir bir sonuç elde edilir. İki temel yaklaşım vardır:

Centralized Measurement Fusion (CMF) : Ham veriler doğrudan füzyon merkezine gönderilir. Teorik olarak en iyi sonucu verir ama çok fazla bant genişliği gerektirir, çoğu gerçek sistemde uygulanamaz.

Track-to-Track Fusion (T2TF): Her sensör kendi içinde tracking yapar ve sadece işlenmiş track bilgisini gönderir. Bant genişliği açısından verimlidir ve gerçek dünya uygulamalarında tercih edilir [Bar-Shalom et al., 2011]. Bizim senaryomuzda kullanılacak olan yöntem de budur.

1.2 Senaryo Tanımı

Bu rapor kapsamında ele alınan senaryo şu özelliklere sahiptir:

Sensör özellikleri:

- Her sensör kendi içinde tracking yapıyor
- Çıktı: Konum (x,y), Hız (vx,vy), Track ID, Track Quality
- Sensörler farklı frekanslarda ölçüm yapıyor (asenكرون)
- Füzyon merkezine geri besleme yok (no feedback)

Temel zorluklar:

- Sensörler farklı zamanlarda ölçüm gönderiyor
- Aynı hedefe ait trackler bağımsız değil (ortak process noise problemi)
- Track quality değerleri quantize edilmiş olabilir
- Hangi tracklerin aynı hedefe ait olduğu bilinmiyor

1.3 Homogen ve Heterogen Füzyon

Sensörlerin aynı state uzayını kullanıp kullanmamasına göre iki durum ortaya çıkar:

Homogen füzyon: Her iki sensör de aynı state vektörünü kullanıyor, örneğin her ikisi de (x, y, vx, vy) üretiyor. Bizim senaryomuz bu kategoriye giriyor çünkü her sensörden konum ve hız alınıyor.

Heterogen füzyon: Sensörler farklı state uzaylarında çalışıyor, örneğin bir radar Kartezyen koordinatta, bir pasif sensör açısıl koordinatta. Bu durum matematiksel olarak çok daha karmaşıktır [Yang et al., 2020].

BÖLÜM 2: Yerel Tracker Seçimi

2.1 Kalman Filter Ailesi

Sensörlerin kendi içinde tracking yapması için bir filtre algoritmasına ihtiyaç vardır. En yaygın seçenekler şunlardır:

Kalman Filter (KF): Doğrusal sistemler için idealdir. Hareket modeli ve ölçüm modeli doğrusal olduğunda teorik olarak en iyi sonucu verir. Hesaplama maliyeti düşüktür.

Extended Kalman Filter (EKF): Doğrusal olmayan sistemler için Kalman Filter'ın genişletilmiş versiyonudur. Doğrusal olmayan fonksiyonları birinci derece Taylor serisi ile doğrusallaştırır. Yang et al.'ın çalışmalarında radar ve pasif sensör füzyonu için kullanılmıştır [Yang et al., 2019; Yang et al., 2020].

Unscented Kalman Filter (UKF): Doğrusal olmayan sistemler için daha iyi bir alternatiftir. Taylor serisi yerine sigma noktaları kullanır. Güçlü nonlinearlik durumlarında EKF'den daha iyi performans gösterir.

EKF ve UKF Karşılaştırması:

EKF birinci derece yaklaşım kullandığı için güçlü nonlinearlik varsa hata birikimi yaşanabilir. UKF ise sigma noktaları aracılığıyla daha yüksek derece nonlinearliği yakalayabilir. Bununla birlikte UKF'nin hesaplama maliyeti EKF'ye göre daha yüksektir. Bizim senaryomuzda sensörler zaten track çıktısı ürettiğinden, yerel filtrenin tipi füzyon merkezi açısından büyük fark yaratmaz. Önemli olan sensörün ürettiği kovaryans matrisinin doğru olmasıdır.

2.2 Senaryo İçin

Sensörler zaten işlenmiş track ürettiğinden füzyon merkezi bu filtrenin iç yapısını bilmek zorunda değildir. Ancak sensörün sağladığı kovaryans bilgisi güvenilir olmalıdır. Track quality değeri bu güvenilirliğin dolaylı bir göstergesidir.

BÖLÜM 3: Track Quality

3.1 Track Quality Nedir?

Track quality, bir track'in ne kadar güvenilir olduğunu ifade eden sayısal bir değerdir. Yüksek kalite gerçek ve iyi takip edilen bir nesneyi, düşük kalite ise yanlış alarm veya zayıf takibi gösterir.

3.2 Track Existence Probability

En yaygın track quality göstergelerinden biri existence probability'dir. Bu değer "bu track gerçek bir nesneye mi ait?" sorusunun olasılıksal cevabıdır.

Bayesian güncelleme ile hesaplanır: Yeni ölçüm geldikçe bu olasılık artarken, ölçüm gelmediği durumlarda azalır. Lindenmaier et al. bu yaklaşımı otonom araç uygulamasında kullanmış ve existence probability tabanlı track management'in M/N mantığına göre çok daha iyi performans gösterdiğini ortaya koymuştur [Lindenmaier et al., 2025].

3.3 Dempster-Shafer Tabanlı Track Quality

Bayesian teorisinin bir genellemesi olan Dempster-Shafer (DS) teorisi üç hipotezi birlikte modelleyebilir: nesne var, nesne yok ve belirsiz. Bu esneklik özellikle sensörün nesneyi göremediği durumlarda avantaj sağlar.

Lindenmaier et al., DS teorisini sensor-to-sensor ve sensor-to-global mimarilerinde karşılaştırmış; sensor-to-global DS füzyonunun daha iyi sonuç verdiğini ancak misdetection durumlarında zayıflık yaşadığını göstermiştir. Bu sorunu çözmek için iki adımlı bir existence probability füzyon yöntemi önerilmiştir [Lindenmaier et al., 2025].

3.4 Quantizasyon ve Dequantizasyon

Sensörler track quality değerini genellikle sınırlı bit genişliğiyle iletir. Bu durum quantizasyon hatasına yol açar.

Uniform quantizasyon aralığı eşit parçalara böler. Basit ve hızlıdır ancak karar eşiği civarındaki bölgelerde hassasiyeti düşüktür.

Non-uniform quantizasyon kritik bölgelere daha fazla seviye tahsis eder. Confirm ve silme eşikleri civarında daha ince ayırım yapılabilir.

Not: 6-8 bit quantizasyon çoğu uygulama için yeterlidir. Bit sayısı azaldıkça eşik kayması artar ve bu durum yanlış track kararlarına yol açabilir. Dequantizasyon sırasında midpoint reconstruction veya error diffusion yöntemleri kullanılarak hata azaltılabilir.

BÖLÜM 4: Track-to-Track Association

4.1 Association Nedir?

Association "hangi trackler aynı hedeften geliyor?" sorusunu cevaplar. Füzyonun en kritik adımıdır çünkü yanlış eşleştirme sonraki tüm adımları bozar.

4.2 Konvansiyonel Association

İki track'in aynı hedeften gelip gelmediği olasılık hesabıyla değerlendirilir. Gaussian varsayımı altında assignment cost şöyle hesaplanır:

$$c = \text{Mahalanobis mesafesi} + \log(\text{inovasyon kovaryansı determinantı})$$

İnovasyon kovaryansı iki track'in kovaryanslarının toplamından cross-covariance çıkarılmasıyla elde edilir. Bu cross-covariance terimi çoğu uygulamada ihmal edilir ya da yaklaşık olarak hesaplanır.

İki sensör için optimal atama Hungarian algoritmasıyla çözülür. Ancak $O(n^3)$ karmaşıklığı nedeniyle yoğun trafik senaryolarında gerçek zamanlı çalışmayı zorlaştırır [Lindenmaier et al., 2025].

4.3 Fuzzy Association Yaklaşımları

İstatistiksel yöntemlere alternatif olarak bulanık mantık tabanlı association yöntemleri de literatürde yer almaktadır. Aziz (2014), çok sensörlü çok hedefli ortamlarda bulanık kümeleme yaklaşımını önermiştir. Bu yöntemlerin avantajı kullanıcı tanımlı eşiklere duyarlılığın azaltılmasıdır; ancak doğruluk açısından istatistiksel yöntemlerin gerisinde kalabilir.

4.4 Informative Prior ile Association

Konvansiyonel association yöntemlerinde "diffuse prior" varsayımı yapılır, yani hedefin nerede olduğuna dair hiçbir ön bilgi yokmuş gibi davranılır. Bu durum hem bilgi kaybına hem de gereksiz hesaplama yüküne yol açar.

Lindenmaier et al.'ın önerdiği yaklaşımda fused track geri beslenerek bir önceki adımdaki bilgi association'a dahil edilir. Böylece "hedef geçen adımda buradaydı, şimdi de buralarda olmalı" bilgisi kullanılarak daha verimli ve doğru bir eşleştirme yapılır [Lindenmaier et al., 2025].

Bizim senaryomuz için not: No-feedback senaryosunda bu tam geri besleme mevcut değildir. Ancak track ID bilgisi kullanılarak geçmiş eşleştirmeler takip edilebilir ve basit bir informative prior oluşturulabilir.

4.5 Duplicate Track Yönetimi

Özellikle radar sensörleri aynı hedefi bazen iki farklı track olarak gösterebilir. Konvansiyonel yöntemler bunu ele almaz ve yanlış alarm oluşmasına yol açar. Lindenmaier et al. duplication probability parametresini log-likelihood hesabına dahil ederek bu sorunu çözmüştür [Lindenmaier et al., 2025].

4.6 Greedy Clustering

Optimizasyon tabanlı çözümler NP-hard olduğundan gerçek zamanlı sistemlerde kullanımları kısıtlıdır. Greedy clustering her adımda en iyi çifti seçerek $O(N^2)$ karmaşıklıkla iyi bir çözüm üretir. Lindenmaier et al. bu algoritmayı duplicate yönetimi ve cluster birleştirme özellikleriyle genişletmiştir [Lindenmaier et al., 2025].

BÖLÜM 5: Cross-Covariance Problemi

5.1 Neden Cross-Covariance Önemli?

İki sensör aynı hedefi takip ettiğinde track tahmin hataları birbirinden bağımsız değildir. Her iki sensör de aynı hedefin hareketinden etkilenir ve bu ortak etki hataların ilişkili olmasına yol açar. Bu ilişkiyi yoksayan füzyon yöntemleri tutarsız sonuçlar üretir.

Matematiksel olarak:

$$P_{\text{füzyon}} = P_i + P_j - P_{ij} - P_{ji}$$

$P_{ij} = 0$ varsayılırsa $\rightarrow$ OPTİMİSTİK kovaryans (gerçekte daha büyük hata var ama sistem bunu bilmiyor)

Bu sorun ilk kez Bar-Shalom (1981) tarafından tanımlanmıştır ve homogen T2TF için çözüm "common process noise" kavramına dayanır [Bar-Shalom et al., 2011].

5.2 Homogen Durumda Cross-Covariance

Bizim senaryomuzda her iki sensör de aynı state uzayında çalıştığından homogen durum geçerlidir. Cross-covariance özyinelemeli olarak hesaplanır:

$$P_{ij}(k|k) = [I - W_i \cdot H_i] \cdot F \cdot P_{ij}(k-1|k-1) \cdot F^T \cdot [I - W_j \cdot H_j]^T + [I - W_i \cdot H_i] \cdot Q_{ij} \cdot [I - W_j \cdot H_j]^T$$

Burada Q_{ij} iki sensörün process noise'ları arasındaki ilişkiyi ifade eder. Homogen durumda process noise ortak olduğundan bu terim doğrudan hesaplanabilir.

5.3 Cross-Covariance Bilinmediğinde Pratik Yaklaşım

Sensör üreticileri çoğunlukla Kalman filter parametrelerini paylaşmaz. Bu durumda cross-covariance yaklaşık olarak tahmin edilebilir:

$$P_{ij} \approx \rho \cdot \sqrt{P_i \odot P_j}$$

$\rho \approx 0.4$ (çoğu uygulama için iyi başlangıç noktası)
 $\odot$ = Hadamard çarpımı (eleman bazlı çarpım)

Bu yaklaşım Lindenmaier et al. tarafından otomotiv uygulamasında kullanılmış ve kabul edilebilir sonuçlar ürettiği gösterilmiştir [Lindenmaier et al., 2025].

5.4 NEES ile Tutarlılık Kontrolü

Füzyonun kalitesini değerlendirmek için NEES (Normalized Estimation Error Squared) kullanılır. Bu parametre sensörün kendine verdiği güven skorunun ne kadar tutarlı olduğunu gösterir:

$$NEES = \hat{x}^T \cdot P^{-1} \cdot \hat{x}$$

İdeal değer = state boyutu (örneğin 4D için NEES = 4)
NEES > ideal → kovaryans iyimser, güvensiz
NEES = ideal → tutarlı sistem

Yang et al. cross-covariance olmadan yapılan füzyonun tutarsız olduğunu ve kovaryansın iyimser kaldığını NEES analiziyle göstermiştir [Yang et al., 2019].

BÖLÜM 6: Asenkron Füzyon

6.1 Asenkron Sistemin Tanımı

Bizim senaryomuzda sensörler farklı frekanslarda çalışır. Bu durum füzyon merkezine farklı zamanlarda farklı sensörlerden veri gelmesi anlamına gelir. (r=radar, k=kamera)

Örnek Zaman Çizelgesi:

Sensör 1:	Her 2.5 saniyede bir						
Sensör 2:	Her 1 saniyede bir						
Zaman:	0	1	2	2.5	3	4	5
S1:	r			r			r
S2:	k	k	k	k	k	k	k

6.2 Asenkron T2TF Yaklaşımı

Asenkron durumda füzyon zamanları iki sensörün ölçüm zamanlarının birleşimidir. Her yeni veri geldiğinde füzyon güncellenir. Sensörden veri gelmediği zamanlarda ise o sensörün son tahmini ileriye propagate edilir.

Yang et al. bu durumu matematiksel olarak ele almış ve cross-covariance hesabını asenkron durum için genelleştirmiştir [Yang et al., 2020]:

$$\begin{aligned} P_{ij}(t_k|t_k) &= [I - \chi_i \cdot W_i \cdot H_i] \cdot \{ F_i \cdot P_{ij}(t_{k-1}|t_{k-1}) \cdot F_j^T + \\ &Q_{ij}(t_k, t_{k-1}) \} \cdot [I - \chi_j \cdot W_j \cdot H_j]^T \\ \chi_i &= 1 \rightarrow \text{Sensör } i \text{ bu anda ölçüm yaptı} \\ \chi_i &= 0 \rightarrow \text{Ölçüm yok, propagasyon kullanılıyor} \end{aligned}$$

Kritik nokta: Füzyon isteğe bağlı yapılabilir ama cross-covariance hesabı her zaman tam hızda çalışmalıdır. Hiçbir adım atlanmamalıdır.

6.3 No-Feedback Senaryosu

Bizim senaryomuzda füzyon sonucu sensörlere geri beslenmez. Bu durum association adımını biraz zorlaştırır çünkü informative prior için kullanılabilecek bilgi sınırlıdır.

Bununla birlikte track ID bilgisi ve zaman damgaları kullanılarak bir önceki füzyon sonucu geçici olarak saklanabilir ve association'a yardımcı olmak amacıyla kullanılabilir. Bu yaklaşım tam geri besleme değildir ama association kalitesini artırır.

BÖLÜM 7: Füzyon Algoritmaları

7.1 LMMSE Füzyon

Linear Minimum Mean Square Error füzyonu, ortalama karesel hatayı minimize eden doğrusal birleştirme yöntemidir.

$$\begin{aligned} \hat{x}_{\text{füzyon}} &= \hat{x}_i + P_{xz} \cdot P_{zz}^{-1} \cdot [\hat{x}_j - g(\hat{x}_i)] \\ P_{xz} &= P_i \cdot G^T - P_{ij} \\ P_{zz} &= P_j - G \cdot P_{ij} - P_{ji} \cdot G^T + G \cdot P_i \cdot G^T \end{aligned}$$

Homogen senaryomuzda g fonksiyonu identity olduğundan denklemler basitleşir. Yang et al. bu yöntemi hem senkron hem asenkron senaryolar için başarıyla uygulamıştır [Yang et al., 2019; Yang et al., 2020].

7.2 Information Matrix Fusion (IMF)

IMF, kovaryans matrisi yerine bilgi matrisi (kovaryansın tersi) üzerinde çalışır. Sensör sayısı arttıkça daha kolay genelleşir ve bazı senaryolarda LMMSE'ye göre daha iyi sonuç üretir. Lindenmaier et al. bu yöntemi asenkron sensörlerle kullanılan bir yaklaşım olarak referans göstermiştir [Lindenmaier et al., 2025].

7.3 Covariance Intersection

Cross-covariance bilinmediğinde kullanılabilen güvenli bir yöntemdir. Her zaman tutarlı (conservative) sonuç üretir ama optimal değildir. Cross-covariance bilgisi mevcut olduğunda LMMSE veya IMF daha iyi performans gösterir.

7.4 Yöntem Karşılaştırması

Yöntem	Cross-cov	Tutarlı	Optimal	Karmaşıklık
LMMSE	Gerekli	Evet	Evet	Orta
IMF	Gerekli	Evet	Evet	Orta
Cov. Intersection	Gerekmez	Evet	Hayır	Düşük
Cov. Union	Gerekmez	Hayır	Hayır	Düşük

Senaryomuz için LMMSE önerilir. Cross-covariance bilinmiyorsa $\rho \approx 0.4$ yaklaşımı kullanılabilir.

BÖLÜM 8: Track Management

8.1 Track Lifecycle

Her global track üç aşamadan geçer:

- **Tentative (Geçici):** Yeni track oluşturuldu, henüz doğrulanmadı. Sadece sistem içinde tutulur, uygulamaya iletilmez.
- **Confirmed (Doğrulanmış):** Existence probability onay eşiğini aştı. Uygulamaya iletilir.
- **Deleted (Silinmiş):** Existence probability silme eşiğinin altına düştü. Track listesinden çıkarılır.

8.2 Track Başlatma

Yeni bir local track geldiğinde mevcut global tracklere eşleştirelemeyen track yeni bir tentative global track başlatır. Bu track'in existence probability'si yerel sensörün kalitesinden başlatılır.

8.3 Track Silme


Bir global track belirli süre boyunca hiçbir sensörden güncelleme alamazsa existence probability düşer ve silme eşiğinin altına indiğinde track listesinden çıkarılır.

8.4 M/N Mantığı vs Existence Probability

M/N mantığı son N frame'de kaç kez tespit edildiğine bakar. Basit ama kaba bir yöntemdir. Lindenmaier et al. bu yöntemin **precision açısından çok yetersiz** kaldığını göstermiştir: M/N mantığının precision değeri %52.81 iken önerilen existence probability tabanlı yöntem %96.55'e ulaşmıştır [Lindenmaier et al., 2025].

BÖLÜM 9: Önerilen Sistem Pipeline'ı

9.1 Genel Mimari



9.2 ADIM 1: Zaman Senkronizasyonu

Asenkron sensörlerden gelen veriler ortak bir zaman eksenine hizalanmalıdır.

Yapılacak işlem: Her yeni sensör verisi geldiğinde diğer sensörlerin son tahminleri bu zamana propagate edilir. Propagasyon için hareket modeli kullanılır.

$$\begin{aligned}\hat{x}_{\text{propagate}}(t_k) &= F(t_k, t_{\text{son}}) \cdot \hat{x}(t_{\text{son}}) \\ P_{\text{propagate}}(t_k) &= F \cdot P(t_{\text{son}}) \cdot F^T + Q(t_k, t_{\text{son}})\end{aligned}$$

Bu adım Yang et al.'ın asenkron formülasyonunda detaylandırılmıştır [Yang et al., 2020].

9.3 ADIM 2: Track Quality Dequantizasyonu

Sensörden gelen track quality değeri genellikle sınırlı bit genişliğinde iletilir.

Yapılacak işlem:

- **Uniform dequantizasyon:** $p(\Xi) = q / (2^n - 1)$
- **Non-uniform (eşik civarında ince ayırım için):** Lookup table kullan

Dequantize edilen değer: Association'da assignment likelihood hesabında ve Track management'ta confirm/delete kararında kullanılacaktır.

9.4 ADIM 3: Track-to-Track Association

Hangi local trackler aynı hedeften geliyor sorusu yanıtlanır.

Önerilen yaklaşım:

Assignment cost her track çifti için hesaplanır:

$$\begin{aligned}c_{\{ij\}} &= (\hat{x}_i - \hat{x}_j)^T \cdot S_{\{ij\}}^{-1} \cdot (\hat{x}_i - \hat{x}_j) + \log|S_{\{ij\}}| \\ S_{\{ij\}} &= P_i + P_j - P_{ij} - P_{ij}^T\end{aligned}$$

Cross-covariance bilinmiyorsa:

$$P_{ij} \approx \rho \cdot \sqrt{(P_i \odot P_j)}, \rho \approx 0.4$$

Unassignment eşiği: Konvansiyonel yöntemlerde bu eşik elle ayarlanır. Lindenmaier et al.'ın önerdiği gibi sensör parametrelerinden otomatik hesaplamak tercih edilmelidir [Lindenmaier et al., 2025].

Duplicate track kontrolü: Aynı sensörden iki track geliyorsa duplication probability parametresi log-likelihood hesabına dahil edilir.

Optimizasyon: İki sensör için Hungarian algoritması, ikiden fazla sensör için greedy clustering önerilir.

9.5 ADIM 4: Cross-Covariance Hesabı

Association sonrası eşleştirilen trackler için cross-covariance güncellenir.

Önerilen yaklaşım:

Sensörün Kalman filter parametrelerine erişim varsa:

$$P_{ij}(k|k) = [I - W_i \cdot H_i] \cdot \{ F \cdot P_{ij}(k-1|k-1) \cdot F^T + Q_{ij} \} \cdot [I - W_j \cdot H_j]^T$$

Parametreler bilinmiyorsa yaklaşık değer kullanılır:

$$P_{ij} \approx 0.4 \cdot \sqrt{(P_i \odot P_j)}$$

Bu adım her füzyon zamanında hesaplanmalıdır, hiçbir adım atlanmamalıdır [Yang et al., 2020].

9.6 ADIM 5: State Füzyon (LMMSE)

Eşleştirilen trackler LMMSE ile birleştirilir.

Homogen senaryoda basitleştirilmiş LMMSE:

$$\begin{aligned}\hat{x}_{\text{füzyon}} &= \hat{x}_i + K \cdot (\hat{x}_j - \hat{x}_i) \\ K &= (P_i - P_{ij}) \cdot (P_i + P_j - P_{ij} - P_{ji})^{-1} \\ P_{\text{füzyon}} &= P_i - K \cdot (P_i - P_{ij})^T\end{aligned}$$

Eşleşmeyen trackler: Sadece tek sensörden gelen trackler o sensörün tahminiyle propagate edilerek global listeye eklenir.

9.7 ADIM 6: Track Management

Her global track için existence probability güncellenir ve yaşam döngüsü yönetilir.

Track güncelleme:

- **Eşleşme VAR:** $p(\exists)$ artar $\rightarrow$ sensörün quality değeri dahil edilir
- **Eşleşme YOK:** $p(\exists)$ azalır $\rightarrow$ misdetection penalty uygulanır

Karar mekanizması:

- $p(\exists) > p_{\text{conf}}$ (örneğin 0.9) $\rightarrow$ Confirmed
- $p(\exists) < p_{\text{del}}$ (örneğin 0.2) $\rightarrow$ Deleted
- Arada $\rightarrow$ Tentative

Track ID yönetimi: Her global track benzersiz bir ID alır. Bu ID no-feedback senaryosunda bile basit bir geçmiş tablosu tutularak association kalitesini artırmak için kullanılabilir.

BÖLÜM 10: Performans Değerlendirmesi

10.1 Kullanılacak Metrikler

- **RMSE (Root Mean Square Error):** Konum ve hız tahmin doğruluğunu ölçer. Ne kadar yarıldığımızı gösterir.
- **NEES (Normalized Estimation Error Squared):** Sistemin kendi hakkındaki güveni ile gerçek performansı arasındaki uyumu ölçer. İdeal değer state boyutuna eşittir. $NEES > \text{ideal}$ ise sistem iyimser davranıyordur ve güvenilmezdir.
- **Precision:** Sistem "nesne var" dediğinde ne kadar doğru. Yanlış alarm filtreleme performansını gösterir.
- **Recall:** Gerçek nesnelerin ne kadarı tespit edildi.
- **F1 Score:** Precision ve Recall'un harmonik ortalaması.
- **MOTA:** Track ID tutarlılığını da hesaba katan çok nesne takip metriği.

10.2 Beklenen Sonuçlar

Yang et al.'ın sonuçlarına dayanarak cross-covariance dahil edildiğinde:

- **Pozisyon RMSE:** %6'ya kadar azalma beklenir
- **Hız RMSE:** %8'e kadar azalma beklenir
- **NEES:** Tutarlı aralığa girer

Lindenmaier et al.'ın sonuçlarına dayanarak informative prior ve existence probability tabanlı TMS kullanıldığında:

- **Precision:** %96 üzeri hedeflenir
- **F1 Score:** %91 üzeri hedeflenir
- **MOTA:** %82 üzeri hedeflenir

BÖLÜM 11: Kaynaklar

- [1] Yang, K., Bar-Shalom, Y., Willett, P. (2019). Track-to-Track Fusion with Cross-Covariances from Radar and IR/EO Sensor. 22nd International Conference on Information Fusion, Ottawa. (Cross-covariance türetmesinin ilk konferans versiyonu. A matrisinin açık formu verilmiş. Tutarlılık analizini öne çıkaran çalışma.)
- [2] Yang, K., Bar-Shalom, Y., Willett, P. (2020). Asynchronous and Heterogeneous Track-to-Track Fusion with Mapped Process Noise and Cross-Covariance. Journal of Advances in Information Fusion, Vol. 15, No. 1. (Asenkron durum ve NCT modeli ile genişletilmiş versiyon. Process noise cross-covariance türetmesi ve LMMSE füzyon formülasyonu.)
- [3] Lindenmaier, L., Czibere, B., Aradi, S., Bécsi, T. (2025). A Robust and Runtime-Efficient Track-to-Track Fusion for Automotive Perception Systems. IEEE Sensors Journal, Vol. 25, No. 8. (Informative prior tabanlı association, duplicate track yönetimi, iki adımlı TMS. Gerçek dünya otoyol verisiyle değerlendirme.)
- [4] Bar-Shalom, Y., Willett, P., Tian, X. (2011). Tracking and Data Fusion. YBS Publishing. (T2TF temel referans kitabı. Homogen füzyon, common process noise, cross-covariance özyinelemesi.)
- [5] Bar-Shalom, Y. (1981). On the Track-to-Track Correlation Problem. IEEE Transactions on Automatic Control. (Cross-covariance problemini ilk tanımlayan çalışma.)
- [6] Aziz, A. M. (2014). Fuzzy Track-to-Track Association Approaches. (Bulanık mantık tabanlı association yöntemleri. Eşik bağımsızlığı avantajı.)
- [7] Matzka, S., Altendorfer, R. (2008). A Comparison of Track-to-Track Fusion Algorithms for Automotive Sensor Fusion. IEEE International Conference on Multisensor Fusion. (LMMSE, IMF, covariance intersection, covariance union karşılaştırması. Cross-covariance yönteminin en iyi performansı gösterdiği referans.)
- [8] Aeberhard, M. et al. (2012). Track-to-Track Fusion with Asynchronous Sensors Using Information Matrix Fusion. IEEE Transactions on Intelligent Transportation Systems. (IMF yöntemi, asenkron sensörler, sensor-to-global mimari.)
- [9] Tian, X., Bar-Shalom, Y. (2010). On Algorithms for Asynchronous Track-to-Track Fusion. International Conference on Information Fusion. (Asenkron homogen T2TF için cross-covariance algoritması.)